

VinDr-Mammo Veri Seti Üzerinde YOLO ile Meme Lezyonu Tespit Pipeline'ı

1. Giriş

Bu çalışmada, VinDr-Mammo veri setinin küçük bir alt kümesi üzerinde, YOLO tabanlı bir bounding box lezyon tespit pipeline'ı tasarlanmış ve uçtan uca uygulanmıştır. Küçük bir alt küme kullanılmasının temel sebebi veri setinin çok büyük olması, gpu gücünün yetersiz ve zamanın kısıtlı olmasıdır. Süreç içerisinde DICOM formatındaki ham görüntülerin işlenmesi, lezyon anotasyonlarından YOLO ile bounding box etiketlerinin üretilmesi, train/test/validation ayrımı yapılarak YOLO modelinin eğitilmesi ve elde edilen sonucun metrikler ve görseller ile analiz edilmesi amaçlanmıştır.

2. Veri Seti ve Çalışma Kapsamı

Çalışmada VinDr-Mammo veri seti kullanılmıştır. Veri setinin büyüklüğü ve çalışma amacından ötürü başlangıçta 50 adet veri (40 lezyonlu 10 lezyonsuz), sonuçların yetersizliği ve overfittingten ötürü daha sonrasında 136 adet veri (96 lezyonlu, 40 lezyonsuz) ile alt kümeler oluşturulmuştur. Veri setinin sağladığı dosyalar:

- breast-level_annotations.csv
- finding_annotations.csv
- metadata.csv

kullanılmıştır. DICOM dosyaları script ile parçalı olarak erişim sağlanamadığı için manuel olarak indirilerek dosyalanmıştır. Lezyon tipi olarak “Mass”, “Suspicious Calcification”, “Asymmetry”, “Architectural Distortion” kategorileri dikkate alınmıştır. Veri setinde bu kategoriler dışında da kategoriler bulunmaktadır. Bu kategoriler lezyonların meme kanseri taramalarında klinik olarak en kritik ve en sık görülen bulgular olmasından ötürü tercih edilmiştir [1]. Ayrıca, veri setinde tutarlı ve yeterli anotasyon içermelerinden ve YOLO mimarisi ile uyumlu yapıda olmalarından ötürü tercih edilmiştir.

Bu dört lezyon tipinden gelen anotasyonları kullanarak, mamografi üzerinde “lezyon var” bölgesini sınırlayan bounding box'lar üretmek ve bir YOLO modeli ile lezyon tespiti yapmaktır. Tespit problemi, pratikte “herhangi bir lezyon” vs “lezyon yok” odağında değerlendirilmiştir.

3. Örnek Seçimi ve Alt Kümelerin Oluşturulması

src/select_samples.py scripti ile temel hedef olarak veri setinden 40 lezyonlu 10 lezyonsuz olmak üzere 50 adet başlangıç alt kümesi seçilmektedir. Her kategori için benzersiz study_id ve image_id çiftleri çıkartılmaktadır. Numpy kullanılarak rastgele fakat tekrarlanabilir seçim yapılmaktadır. Sonuçta elde edilen study_id ve image_id çiftleri, breast, finding ve metadata ile birleştirilerek data/processed/subset_samples.csv dosyası oluşturulmaktadır. Kontrollü ve dengeli bir alt küme oluşturulmaktadır.

Çalışmanın devamında oluşturulan alt kümenin eğitim aşamasında çok yetersiz kalması ve overfitting oluşmasından ötürü örnek sayısının hedefe yönelik arttırılabilmesi için src/expand_subset.py scripti oluşturulmuştur. Bu aşamada alt kümedeki veri sayısının 150'ye çıkartılması hedeflenmiş ve dağılım 110 lezyonlu, 40 lezyonsuz olarak belirlenmiştir. Elde edilen veriler ise 96 lezyonlu ve 40 lezyonsuz olmuştur, pipeline oluşturmak için ve daha yeterli sonuç vereceği için sonraki aşamalar ile devam edilmiştir.

src/expand_subset.py scriptinde önce subset_samples.csv dosyası okunur ve aynı verilerin kullanılarak üzerine ekleme yapılması sağlanır. Ardından tekrar kategoriler çıkartılarak hedeflenen dört lezyon tipinin filtrelemesi gerçekleştirilir. Mevcut alt kümede bulunan lezyonlu ve lezyonsuz örnek sayıları hesaplanarak hedefe uygun yeni lezyonlu ve lezyonsuz örnekler seçilir. Elde edilen sonuç, metadata ve anotasyonlar ile birleştirilerek data/processed/subset_samples_150.csv dosyası oluşturulur. Oluşturulan bu dosya pipeline'ın geri kalanında referans csv olarak kullanılmıştır.

4. DICOM – PNG Dönüşümü

DICOM görüntüleri doğrudan YOLO ile eğitime uygun formata sahip değildir. src/dicom_to_png.py scripti kullanılarak data/raw/dicoms pathinde bulunan alt küme olarak seçilmiş DICOM dosyaları PNG formatına dönüştürülmektedir. Script sayesinde .dicom formatındaki görüntüler 8-bit gri tonlamalı PNG görüntülerine dönüştürülmektedir. YOLO varsayılan olarak 1 kanal yani grayscale ya da 3 kanal RGB input formatını kabul etmektedir. DICOM görüntüleri ise genellikle 12-bit, 14-bit veya 16-bit pixel depth'e sahiptir. YOLO, bu yüksek bit derinliğini desteklememektedir ve bu sebeple dicom görüntüleri YOLO için normalize edilip 8-bit'e çevrilmektedir.

Script ile pydicom modülü kullanılarak dicom dosyaları okunur ve pixel arrayler elde edilir. Pixel array, dicom dosyası içindeki ham görüntü verisini temsil eden numpy dizisidir. Her eleman, meme dokusunun X-ray yoğunluğunu temsil eder. Bu yapı üzerinden kontrast normalizasyonu, VOI LUT uygulaması ve 8-bit dönüşüm gibi preprocessing adımları gerçekleştirilir. Pixel arraylerin elde edilmesinin ardından VOI LUT uygulandı. Önerilen pencereleme ve kontrast dönüşümü uygulanmış oldu. DICOM pikselleri klinik görünürlükte normalize edilmiş oldu. Lezyonların model tarafından daha doğru şekilde algılanmasını sağlar. Photometric Interpretation kontrol edildi. "MONOCHROME2" siyah arka plan ve beyaz yoğunluktur, direkt kullanılır. "MONOCHROME1" ise tam tersidir ve kullanım için ters çevrilir. Tüm bu işlemlerin ardından her bir görüntü önce [0,1] aralığında normalize edilir ve [0,255] aralığına ölçeklenir. Ölçeklenen görüntüler son olarak uint8 formatına çevrilir. Son adım olarak her bir görüntü PNG formatında kaydedilir.

5. YOLO Formatında Etiket Üretimi

Bounding box anotasyonlarının YOLO formatına dönüştürülmesi src/create_yolo_label.py scripti ile gerçekleştirilmiştir. İlk olarak finding_annotations.csv dosyasındaki finding_categories sütunu Python listesi olarak parse edilmiş ve dört ana lezyon kategorisi yeniden etiketlenmiştir. "Asymmetry" kategorisi altında geçen varyasyonlar tek bir sınıf olarak ele alındı. Belirlenen kategori-sınıf eşleşmeleri CLASS_MAP sözlüğünde tanımlandı. CLASS_MAP her lezyon kategorisine karşılık gelen sayısal sınıf id'sini saklar. YOLO integer istediği ve string kabul etmediği için CLASS_MAP kullanılmaktadır.

Ardından subset_samples_150.csv içerisinde otomatik olarak doğru study_id kolonunu bulur. Bu alt küme ile kesişen lezyon anotasyonları filtrelenir. Yalnızca kullanılacak görüntülere ait anotasyonlar işlenmiş olur. Bounding box koordinatları YOLO'nun gerektirdiği şekilde normalize edilmiş hale dönüştürülür.

YOLO, bounding box'ları normalleştirilmiş merkez–genişlik formatında bekler. Bu nedenle VinDr-Mammo anotasyonlarında verilen piksel tabanlı xmin, ymin, xmax, ymax değişkenlerinin YOLO formatına dönüştürülmesi gerekmektedir. YOLO bounding box formatı şu bilgileri içermektedir:

- Box merkezinin x koordinatı
- Box merkezinin y koordinatı
- Box genişliği
- Box yüksekliği

İlk olarak merkez koordinatları bulunur ve bu merkez koordinatları bulunur. Ardından box genişliği ve yüksekliği hesaplanır. Dönüşümlerin gerçekleştirilmesinin ardından her anotsayon satırı “<class_id> <xc> <yc> <w> <h>” formatında dosyaya yazdırılır. Bu aşamada yapılan dönüşüm, farklı çözünürlüklere sahip görüntülerinin model tarafından tutarlı bir şekilde işlenmesine olanak tanır ve tespit performansı için önemlidir.

YOLO mimarisi bir görüntü içerisinde hiçbir hedef nesne bulunmuyor olsa bile etiket dosyası bulunmasını bekler. Herhangi bir hedef nesne bulunmayan yani bu çalışma için lezyonsuz veriler için boş etiket dosyası oluşturulması gerekmektedir. Eğer bu işlem gerçekleştirilmez ise YOLO bu görüntüyü tamamen dışlayarak veri dengesizliğine ve hatalara sebep olur. Sonuç olarak lezyonlu veriler en az bir satır içeren, lezyonsuz görüntüler boş .txt dosyalarına sahip olur.

6. YOLO Train/Test/Validation Oluşturulması

YOLO modellerinin eğitilebilmesi için görüntülerin ve etiket dosyalarının belirli bir dizin yapısına yerleştirilmesi ve eğitim–doğrulama–test splitlerinin standart bir biçimde oluşturulması gerekmektedir. Bu çalışma kapsamında bu işlemler src/prepare_yolo_dataset.py scripti ile otomatik olarak gerçekleştirilmiştir. Öncelikle genişletilmiş alt küme olan subset_samples_150.csv dosyası okunmuştur. Bu CSV, alt seçilmiş tüm görüntüler için study_id ve image_id bilgilerini içerdiğinden, YOLO split işlemi için temel referans set olarak kullanılmıştır.

YOLO’da her görüntü bir defa olması gerektiği için benzersiz study_id ve image_id çiftleri alınır. Split işleminin stratified yapılması, yani her alt kümede lezyon–lezyonsuz oranının sabit tutulması önemlidir. Bu sebeple “has_lesion = 0” ve “has_lesion = 1” olarak belirlenen görüntüler ile 112 görüntü train, 12 görüntü validation, 12 görüntü test olarak ayrılır. data/processed/yolo klasörü içerisine görüntüler ve label’lar kaydedilir. images/train/ path’inde görüntü, labels/train path’inde label saklanır. YOLO’nun çalışabilmesi için yapılandırma dosyası gerekmektedir. Script sonunda data.yaml dosyası otomatik olarak oluşturulur.

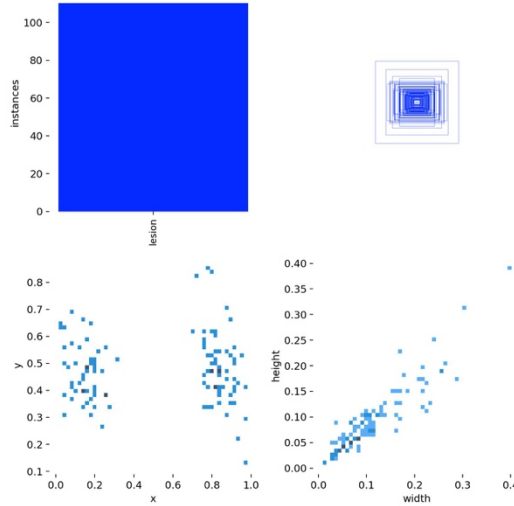
7. Model ve Eğitim Süreci

Bu çalışma kapsamında, meme lezyonlarının bounding box düzeyinde tespiti için YOLOv8 kullanılmıştır. Çalışmada pipeline kurulması amaçlandığı ve veri boyutu sınırlı alındığı için, modelin aşırı karmaşık yapılandırılması yerine daha küçük ve hafif bir YOLO modeli olarak kullanılması tercih edilmiştir. Eğitim süreci ultralytics YOLO framework’ü ile gerçekleştirilmiştir. Model olarak yolov8n.pt tercih edilmiştir. Veri setinin küçük ve dengesiz olması, önceden eğitilmiş ağırlıklara sahip olması -yolov8n.pt ön bilgili bir

modeldir-, hesaplama kaynakları ve sınırlı süreden kaynaklı bu model tercih edilmiştir. Çalışmanın ileriki aşamalarında veri setinin artırılması durumunda yolov8s ya da yolov8m gibi daha büyük modellere geçilebilir. İmgsz olarak 1024 tercih edilmiştir. Default olan 640'a göre küçük lezyon boyutlarının korunmasını sağlamak amaçlanmıştır. Ekstra olarak bounding box tespit doğruluğunda iyileşme olması beklenmektedir. Epoch sayısı 100 ve early stopping için 20 epoch sınırı seçilmiştir. Overfitting'in engellenmesi amaçlanmıştır. Batch olarak 16 seçilmiştir. GPU üzerinden eğitim gerçekleştirilmiştir. Veri augmentation parametreleri scale = 0.5, mosaic = 1.0 mixup = 0 ve copy_paste = 0.1 seçilmiştir. Scale orta düzey ölçeklendirilerek lezyon yerinin konum ve boyut değişimine karşı modelin daha dayanıklı olması amaçlanmıştır. mosaic aktif olarak ayarlandı, görüntüleri birleştirerek çeşit oluşturmaktadır. mixup kapalı olarak ayarlandı, anatomik bütünlüğü bozmasını engellemek amacıyla bu tercih yapıldı.

8. Sonuçlar


Eğitimden önce elde edilen etiket dağılım görselleri, veri setindeki lezyon konumlarını ve sınıf dağılımlarını incelemek amacıyla kullanıldı. Etiket görseli, alt küme içerisinde lezyonların meme görüntüsü içinde rastlantısal olmayıp belirli anatomik bölgelere doğru yoğunlaştığını göstermektedir. Bu durum, modelin bazı bölgelerde daha sık örnek görebildiğini, ancak diğer bölgelerde veri çeşitliliğinin sınırlı olabileceğini işaret etmektedir.



Şekil 1: Lezyon etiketlerinin dağılımı ve konumsal analiz


Üst soldaki grafik, veri setinde yalnızca tek bir lesion çeşidi bulunduğunu ve toplam örnek sayısını göstermektedir. Üst sağdaki grafik, tüm lezyon bounding box'larının normalize edilmiş koordinatları kullanılarak üst üste çizilmiş halidir. Bu, modelin gördüğü lezyon kutularının genel boyut ve konum çeşitliliğini gösterir. Alt sol grafik, lezyon merkezlerinin konumsal dağılımını göstermekte olup lezyonların meme görüntüsü içinde belirli anatomik bölgelerde (görselin solu ve sağ) yoğunlaştığını ortaya koymaktadır. Alt sağ grafik ise bounding box genişlik ve yükseklik dağılımlarını göstermektedir. Lezyonların çoğunun küçük boyutlarda olduğunu ve YOLO için zorlayıcı olduğunu göstermektedir. Bu analiz, veri seti içindeki lezyon çeşitliliğini ve konumsal dağılımı anlamak açısından kritik öneme sahiptir.

Etiket korelogramı ise lezyonların konumsal ilişkilerini ve yoğunluk dağılımlarını daha detaylı biçimde göstermektedir. Bu analiz, lezyon yoğunluğunun merkez bölgelerde arttığını ve uç bölgelerde daha sınırlı olduğunu ortaya koymuştur.




Şekil 2: Lezyon bounding box özelliklerinin pairwise dağılımı


Eğitim sırasında YOLO'nun otomatik olarak uyguladığı veri augmentation teknikleri sayesinde modelin gördüğü örneklerin çeşitliliği artırılmıştır. Eğitim batch görselleri, anotasyonların doğru yüklendiğini ve bounding box'ların doğru biçimde işlendiğini doğrulamak için incelenmiştir. Bu görseller, bounding box etiketlerinin görüntüye doğru şekilde hizalandığını ve augmentasyon sonrası anotasyonların bozulmadan korunduğunu göstermektedir.



Şekil 3: train_batch0.jpeg




Şekil 4: train_batch1.jpg




Şekil 5: train_batch2.jpg

Doğrulama setindeki örnekler üzerinde hem gerçek anotasyonlar hem de model tahminleri görselleştirilmiştir. Gerçek etiketlerin gösterildiği val_batch0_labels.jpg görseli, referans olarak kullanılan lezyon bölgelerini göstermektedir. Bu görüntüye karşılık gelen model tahmini görseli val_batch0_pred.jpg, modelin belirgin Mass gibi geniş yapıli lezyonları başarıyla yakalayabildiğini, ancak küçük mikrokalsifikasyon kümeleri veya ince distorsiyon yapılarında zorlandığını ortaya koymuştur.




Şekil 6: Ground truth (val_batch0_labels.jpg)



Şekil 7: Model predictions (val_batch0_pred.jpg)


Tek sınıflı lezyon tespiti için oluşturulan konfüzyon matrisi (confusion_matrix.png), modelin kaç doğru pozitif (TP), kaç yanlış negatif (FN) ve kaç yanlış pozitif (FP) ürettiğini özetlemektedir.



Şekil 8: YOLOv8 modelinin doğrulama kümesi için ürettiği karışıklık matrisi (confusion matrix)

Confusion matrisi, YOLOv8 modelinin doğrulama kümesindeki performansını göstermektedir. Model gerçek lezyonların yalnızca küçük bir kısmını doğru tespit etmiş (3 adet doğru pozitif), buna karşılık büyük çoğunluğunu background olarak sınıflandırarak (15 adet yanlış negatif) belirgin bir recall düşüklüğü sergilemiştir. Ayrıca background sınıfına ait 4 örnek yanlış şekilde lezyon olarak etiketlenmiş olup bu durum modelin meme içi doku yoğunluklarını lezyonla karıştırma eğiliminde olduğunu göstermektedir. Genel olarak model, sınıf dengesizliği, lezyonların küçük ve düşük kontrastlı yapısı ve kullanılan YOLOv8n nedeniyle aşırı temkinli davranarak çoğu örneği background olarak tahmin etmiştir. Bu sonuçlar, mevcut modelin klinik tespit için yeterli olmadığını ancak daha büyük modeller, ek veri artırma stratejileri ve daha dengeli bir eğitim seti ile performansın geliştirilme potansiyeli bulunduğunu göstermektedir.


Normalize konfüzyon matrisi (confusion_matrix_normalized.png) ise modelin özellikle recall tarafında zorlandığını göstermektedir. Yani model bazı gerçek lezyonları tespit edememiştir.



Şekil 9: Normalize edilmiş confusion matrisi

Bu grafik, modelin test kümesi üzerindeki tahmin performansını oransal olarak göstermektedir. Gerçek lezyon örneklerinin yalnızca %17'si doğru tespit edilirken, %83'ü background olarak sınıflandırılmıştır. Background sınıfındaki örneklerin ise %100'ü yanlış biçimde lezyon olarak tahmin edilmiştir. Bu dağılım, modelin hem yüksek yanlış negatif oranına hem de belirgin bir yanlış pozitif eğilimine sahip olduğunu, dolayısıyla karar sınırlarını yeterince öğrenemediğini ortaya koymaktadır.


Precision–Recall eğrisi (PR_curve.png), modelin karar eşiği değiştikçe precision ve recall değerlerinin nasıl değiştiğini göstermektedir. Eğrinin nispeten düşük bir alana sahip olması, veri miktarının azlığı ve lezyon çeşitliliğinin sınırlı olmasıyla tutarlıdır.



Şekil 10: Precision-Recall eğrisi

Bu eğri, modelin karar eşiği değiştirildikçe precision ve recall arasındaki ilişkinin nasıl değiştiğini göstermektedir. Düşük recall değerleri, modelin birçok lezyonu kaçırdığını; precision'ın hızla düşmesi ise karar eşiği gevşedikçe yanlış pozitiflerin arttığını göstermektedir. Bu davranış, küçük ve az veriyle eğitilmiş tek sınıflı tespit modellerinde tipik olarak görülen erken performans sınırlamalarını yansıtmaktadır.

Precision eğrisi (P_curve.png) incelendiğinde modelin belirli eşiklerde yüksek precision elde ettiği görülmüştür; bu da yanlış pozitif eğiliminin düşük olduğunu gösterir.




Şekil 11: Precision-Confidence eğrisi (P_curve)

Eğri, düşük güven aralıklarında precision'ın oldukça düşük seviyelerde başladığını ve modelin düşük eşiklerde çok sayıda yanlış pozitif ürettiğini ortaya koymaktadır. Confidence değeri yaklaşık 0.3–0.5 aralığına çıktığında precision belirgin şekilde artmakta, bu da modelin yalnızca daha emin olduğu tahminlerde nispeten daha doğru sonuçlar verdiğini göstermektedir. Eğrinin 0.49 civarında maksimum precision'a ulaşması, bu eşik değerinin test verisi üzerinde güvenilirlik-optimal bir bölge olduğunu işaret etmektedir. Bununla birlikte, modelin genelleme kapasitesinin düşük olması nedeniyle yüksek precision

değerleri yalnızca sınırlı sayıda tahminde gözlenmiş, bu da veri miktarının azlığı ve tek sınıflı yapının oluşturduğu performans kısıtlarıyla uyumludur.


Recall eğrisi (R_curve.png) ise modelin düşük eşiklerde bile sınırlı miktarda lezyon yakalayabildiğini, yani recall skorunun büyük ölçüde düşük kaldığını göstermektedir.



Şekil 12: Precision-Confidence eğrisi (R_curve)

Eğri, çok düşük confidence seviyelerinde recall'ın en yüksek olduğu bölgeyi temsil eder; çünkü model bu bölgede neredeyse tüm tahminlerini “lezyon” olarak değerlendirmekte ve dolayısıyla daha fazla gerçek pozitif yakalamaktadır. Ancak confidence eşiği yükseldikçe model daha seçici hale gelir ve yalnızca en emin olduğu tahminleri kabul ettiği için recall hızla düşmektedir. 0.2–0.4 confidence aralığında recall'ın belirgin şekilde azaldığı görülmektedir. Bu durum, modelin düşük güven skoruna sahip birçok gerçek lezyonu kaçırdığını ve erken aşamada agresif filtreleme ile performans kaybı yaşadığını göstermektedir. Eğrinin 0.5 üzerindeki confidence değerlerinden itibaren recall'ın neredeyse sıfıra inmesi, modelin yüksek güven seviyelerinde yalnızca çok sınırlı sayıda tespitte bulunabildiğini ve veri kısıtından dolayı yeterince güçlü temsil öğrenemediğini göstermektedir. Bu davranış, küçük veri setlerinde yaygın olarak gözlenen düşük genelleme ve düşük hassasiyet problemiyle tutarlıdır.

F1 eğrisi (F1_curve.png), precision–recall dengesinin zayıf olduğunu ve modelin daha çok precision yönünde ağırlık verdiğini göstermektedir.



Şekil 13: F1-Confidence curve

Eğri incelendiğinde, F1 değerinin düşük confidence seviyelerinde sıfıra yakın başladığı, confidence yaklaşık 0.1–0.25 aralığında ise belirgin bir tepe yaparak en yüksek seviyesine ulaştığı görülmektedir. Bu durum, modelin en dengeli performansı orta-düşük güven eşiğinde verdiğini; yani daha fazla tahmin yapıp bazı yanlış pozitifleri kabul etmesine rağmen daha fazla gerçek pozitif yakalayarak F1 skorunu yükselttiğini göstermektedir. Confidence değeri arttıkça F1 hızla düşmekte ve 0.4’ten sonra neredeyse sıfıra inmektedir; bu, yüksek güven eşiğinde modelin aşırı seçici hâle geldiğini ve çoğu lezyon tespitini filtrelediği için recall’ın çökmesine neden olduğunu göstermektedir. Bu eğilim, küçük veri seti ve sınırlı anotasyon çeşitliliği nedeniyle modelin genelleme kapasitesinin düşük olduğuna dair önemli bir gösterge niteliğindedir.

Modelin test seti üzerindeki sayısal performans metrikleri, lezyon tespitinin sınırlı veri ve yüksek anatomik değişkenlik içeren bir problemde nasıl sonuç verdiğini göstermektedir. Elde edilen değerler yaklaşık olarak Precision = 0.41, Recall = 0.17, mAP@0.5 = 0.17 ve mAP@0.5:0.95 = 0.10 şeklindedir. Bu sonuçlar, modelin özellikle belirgin, kontrastı yüksek ve boyut olarak daha büyük lezyonları tespit etme eğiliminde olduğunu, dolayısıyla tahmin yaptığında çoğunlukla doğru tespit ettiğini göstermektedir; bu durum precision’ın orta seviyede olmasına rağmen recall’ın düşük kalmasıyla uyumludur. Recall değerinin 0.17 gibi düşük bir seviyede olması, veri setindeki gerçek lezyonların önemli bir kısmının model tarafından hiç tespit edilemediğini, yani modelin “atlama” eğiliminde olduğunu göstermektedir.

Sonuç olarak model, küçük bir mamografi alt kümesi ile eğitilmesine rağmen belirgin lezyonları tespit edebilecek bir öğrenme kapasitesi geliştirmiştir. Ancak veri miktarı ve çeşitliliğinin sınırlı olması nedeniyle genelleme kapasitesi zayıf kalmıştır. Buna rağmen pipeline düzgün çalışmış, anotasyonlar doğru işlenmiş ve YOLO mimarisi ile tamamen uçtan uca bir mamografi tespit sistemi başarıyla uygulanmıştır.

9. Tartışma

Bu çalışma kapsamında, VinDr-Mammo veri setinden seçilen sınırlı bir alt kümeyle tam bir uçtan uca meme lezyonu tespit pipeline’ı geliştirilmiş ve YOLO mimarisi üzerinde uygulanmıştır. Pipeline’ın başarılı şekilde kurulması, veri toplama, ön işleme, etiket dönüştürme, train/val/test ayrımı ve model eğitimi gibi gerçek klinik iş akışlarını simüle eden önemli adımların tamamlandığını göstermektedir.

Bununla birlikte, modelin performansını etkileyen önemli sınırlılıklar bulunmaktadır. Çalışmada kullanılan alt kümenin yalnızca 136 görüntü içermesi ve bunların 96'sının lezyonlu olması, özellikle küçük ve karmaşık yapıları lezyonların öğrenilmesini güçleştirmiştir. Mamografi görüntüleri yüksek varyasyon içerdiğinden, küçük veri seti hem genelleme kapasitesini azaltmakta hem de modele yeterli çeşitliliği sunamamaktadır. Bu durum özellikle recall değerlerinin düşük olmasına yansımış, yani model pek çok gerçek lezyonu tahmin edememiştir. Bunun temel nedeni, modelin yeterli örnek görememesi ve bu nedenle düşük kontrastlı veya çok küçük anormallikleri öğrenememesidir. Aynı zamanda tüm lezyon tiplerinin tek bir sınıf "lesion" altında toplanması, YOLO'nun farklı morfolojilere sahip lezyonları ayırt etmek yerine hepsini ortak bir temsil üzerinden öğrenmek zorunda kalmasına yol açmış ve modelin ayırt edici özellikleri yakalamada zorlanmasına neden olmuştur.

Ek olarak, model yalnızca YOLO'nun varsayılan augmentasyonlarıyla eğitilmiştir. Tıbbi görüntüler için özel augmentasyonların kullanılmaması, özellikle düşük kontrastlı bölgelerde modelin genellemesini sınırlamış olabilir. Hiperparametre arayışı yapılmaması ve sınırlı hesaplama gücü nedeniyle deney sayısının kısıtlı olması da performansı etkileyen faktörler arasındadır. Bununla birlikte, mevcut pipeline daha büyük veri setlerine ve daha gelişmiş modellerle yapılacak denemelerle temel oluşturabilecek sağlam bir yapı sağlamaktadır.

10. Sonuç

Bu çalışma, VinDr-Mammo veri setinden elde edilen sınırlı bir alt küme ile YOLO tabanlı meme lezyonu tespit pipeline'ının başarıyla kurulup uygulanabileceğini göstermiştir. DICOM formatındaki ham mamografi görüntülerinden başlayarak, YOLO formatında etiket üretimi, veri bölünmesi, model eğitimi ve performans değerlendirmesi gibi kritik adımların tamamı sistematik biçimde gerçekleştirilmiştir. Elde edilen sonuçlar, sınırlı veriye rağmen modelin belirgin lezyonları yakalayabildiğini, ancak özellikle küçük ve düşük kontrastlı lezyonlarda zorlandığını göstermektedir.

11. Referanslar

[1] Nguyễn Minh Hiếu et al., "VinDr-Mammo: A large-scale benchmark dataset for computer-aided diagnosis in full-field digital mammography," Scientific Data, vol. 10, no. 1, May 2023, doi: <https://doi.org/10.1038/s41597-023-02100-7>.